

# Satisfacción/Optimización de Restricciones II

---

Víctor Giménez

Inteligencia Artificial - 2021/2022 1Q

CS - GEI- FIB

# Generalización

---

Hasta ahora hemos escrito el algoritmo teniendo un tipo de propagador de la restricción concreto (arco entre dos variables). ¿Se puede generalizar? ¿Qué aporta generalizarlo?

Componentes del estado hasta ahora:

- Variables
- Dominios (valores posibles para las variables) **EXPLÍCITOS**
- Restricciones **binarias** entre las variables

Constará de 2 fases:

- Propagación de restricciones de forma inteligente (antes, arco-consistencia)
- Búsqueda de valores dentro de los todavía posibles (asignación igual que antes, o incluso más sofisticado)

- Representación **funcional** (posiblemente parcial) de una restricción
- Un propagador es una función de  $D$  a  $D$  (domain-to-domain) que 'reduce' el dominio de una *variable* en función del dominio actual (del resto de variables).
  - En una restricción binaria  $r$ , tenemos 2 propagadores, uno para cada variable  $(X, Y)$  y que depende de la otra.
  - Ahora los definimos más 'formalmente' en función de la restricción que codifican realmente. Esto requiere de un 'traductor' de restricción a propagadores (antes usábamos una comprobación directa de compatibilidad entre pares de valores).
  - Ejemplo  $D'(X) = \{x \in D(X) \mid \exists y \in D(Y) : compatible(x, y)\}$  y viceversa.

# Tipos de propagadores

- Un propagador puede ser un propagador de dominio (el más informado) o de otro tipo (como de límites).
- Ejemplo de propagadores para  $X = |Y|$ 
  - **Dominio** (Equivale a arco-consistencia)
    - $D'(X) = D(X) \cap [D(Y) \cup D(-Y)] \setminus [-\infty..-1]$ : valores en ambos dominios sin contar signo deben coincidir, y X debe ser positiva.
    - $D'(Y) = D(Y) \cap [D(X) \cup D(-X)]$ : lo mismo, pero Y puede ser negativa.
    - Ejemplo para  $D(X) = \{-4, 0, 3, 10\}$ ,  $D(Y) = \{3, 4, 10\}$ :  
 $D(Y) = \{3, 4, 10\} \rightarrow D(X) = \{3, 10\} \rightarrow D(Y) = \{3, 10\}$
  - **Límites**
    - $D'(X) = D(X) \cap [0..m]$ ,  $m = \max(D(Y), -\min(D(Y)))$ : X puede ir de 0 hasta el máximo en valor absoluto de Y.
    - $D'(Y) = D(Y) \cap [-\max(D(X)), \max(D(X))]$ : Y puede ir de del máximo de X en negativo a en positivo.
    - Ejemplo para  $X = \{-4., 10\}$ ,  $Y = \{-4., 10\}$ :  $X = \{0., 10\}$ ,  $Y = \{-4., 10\}$
- ¿Por qué nos importaría el de límites si el otro reduce mejor los dominios?

# Algoritmo de propagación

---

**Function:**  $\text{propagation}(F_o, F_n, D)$

---

$F = F_o \cup F_n, Q = F_n$

**while** *not*  $Q.\text{empty}()$  **do**

$f = \text{choose}(Q)$

$D' = f(D)$

$Q = Q \cup \text{wake}(f, F, D, D')$

$D = D'$

**return**  $D$

---

- $F_o$  son propagadores que 'inicialmente' no hay que mirar (truco para luego).
- Tenemos una cola ( $Q$ ) con propagadores que sí hay que mirar
- A cada iteración, escogemos un propagador y lo propagamos. Luego, añadimos propagadores que 'despiertan'. En arcoconsistencia: añadir todos los arcos originados en la variable cambiada.
- Sutileza: ¡no limitamos los propagadores a afectar a una variable! Asumimos que trabajan a nivel del dominio general, y que 'wake' ya sabrá qué toca despertar.
- Cada solver programa esto con sus heurísticos propios

# Algoritmo de propagación y Búsqueda

---

```
Function: prop_search( $F_o, F_n, D$ )  
D = propagation( $F_o, F_n, D$ )  
if  $D = \emptyset$  or  $\forall X |D(X)| = 1$  then  
     $\perp$  return D  
 $X = choose(vars(D) \setminus fixed(D))$   
 $F = F_o \cup F_n$   
foreach  $v \in D(X).order\_by\_heuristic()$  do  
     $D' = prop\_search(F, \{new\_propagator(X=v)\}, D)$   
    if  $D' \neq \emptyset$  then  
         $\perp$  return  $D'$ 
```

---

- Se llama con  $prop\_search(\emptyset, F, D)$ , todos los propagadores se tienen que comprobar primero.
- $fixed(D)$  devuelve las variables con dominio 1 (fijadas a un valor).
- $choose$  y  $order\_by\_heuristic()$ : Hay mejores y peores, definen la estrategia de resolución. La mayoría de programas modernos permiten sobreescribirlas, pero hay defaults.
- $propagation$  permite explorar solo los propagadores que me importan: un propagador fija  $X$ , y 'wake' se encargará de despertar al resto de propagadores si hace falta.
- Se puede cambiar el bucle de búsqueda para ser más sofisticado, como usar propagadores tipo  $new\_propagator(X < v)$  para hacer búsqueda dicotómica.



¿Cómo pasar de satisfacción de restricciones a optimización de restricciones?

- De DFS pasamos a BranchBound añadiendo que 'podamos' caminos en función del coste.
- Podemos hacer lo mismo aquí: dada una variable numérica  $O$  a maximizar (o minimizar), encontrada una solución de coste  $v$ , la guardamos y añadimos a todos los Fs del stack  $new\_propagator(O > v)$  para ver si hay algo mejor.
- Si esta es la técnica a seguir, es buena idea configurar los heurísticos para diezmar los valores posibles de la variable objetivo: buscando podar el espacio lo antes posible. Por ejemplo, asignando  $O$  la primera con un propagador  $new\_propagator(O > mid(O))$ . Las mejoras son exponenciales.



**MiniZinc** es un programa (con IDE) para la descripción en alto nivel de problemas CSP y COP. El lenguaje de alto nivel se compila a restricciones de bajo nivel (con más variables y loop unrolling). Luego, se traduce a un lenguaje de propagadores propio de cada solver disponible (eg. GeCode) optimizado para dichos propagadores.

El lenguaje además permite el uso de constraints 'globales' ultra optimizadas para cada *solver* (como *all\_different(Vars)*)